

Тема 38. Выполнить визуализацию и расширенный анализ данных в Pandas и NumPy (группировка, агрегирование, построение графиков).

Выполнение группировки, агрегирования и визуализации данных в pandas и NumPy позволяет студентам переходить от «ручного» анализа в Excel к системной, воспроизводимой аналитике на уровне, которого требуют цифровая экономика и национальные стандарты ИИ-грамотности Казахстана. Это вписывается в модель *acquire* → *deepen* → *create* и поддержку аналитических компетенций, обозначенных в «Білім. 2025» и «Цифровом Казахстане» через развитие работы с данными и проектное обучение.

1. Введение

1.1 Актуальность темы для «Применения ИКТ» и цифровой экономики

Национальная концепция использования ИИ в образовании Казахстана на 2025–2029 годы, оформленная совместным приказом министра образования и министра цифрового развития, впервые вводит единые стандарты по этике ИИ, защите данных и академической честности, а также по развитию ИИ- и дата-грамотности учащихся по модели *acquire* → *deepen* → *create*. В документе отдельно подчёркивается необходимость интеграции тем, связанных с анализом данных, в предметы «Цифровая грамотность» и модули ИКТ, а также ориентация на проектное обучение.

Отчёт UNESCO по развитию ИКТ-навыков в Республике Казахстан показывает, что цифровая трансформация (в том числе программа «Цифровой Казахстан») требует кадров, умеющих работать с большими массивами данных, проводить расширенный анализ, визуализировать результаты и использовать ИИ-инструменты. Библиотеки pandas и NumPy де-факто стали стандартом в анализе данных на Python, входя в учебные специализации по анализу данных и ИИ.

Для модуля «Применение ИКТ» освоение группировки, агрегирования и визуализации в pandas и NumPy:

- развивает данных-ориентированное мышление;
- готовит студентов к задачам колледжа, бизнеса и госорганов;
- создаёт основу для дальнейшего изучения машинного обучения и облачных платформ (BigQuery, Spark и т.п.).

1.2 Основные определения

1.2.1 NumPy

NumPy описывается как фундаментальная библиотека для научных вычислений в Python, предоставляющая многомерные массивы (ndarray), векторизованные операции, линейную алгебру и ряд математических функций. Простыми словами: *NumPy* — это «быстрый

калькулятор для больших наборов чисел», который умеет работать с массивами гораздо эффективнее, чем стандартные списки *Python*.

1.2.2 pandas

pandas в официальной документации позиционируется как библиотека для работы с табличными и метко-ориентированными данными, предоставляющая структуры *Series* (1D) и *DataFrame* (2D) и богатый набор операций по фильтрации, группировке, агрегированию, преобразованию и визуализации. Простыми словами: *pandas* — это «умный *Excel* внутри *Python*», который позволяет управлять таблицами через код и легко создавать сложные отчёты.

1.2.3 Группировка и агрегирование

Документация *pandas* определяет *groupby* как реализацию парадигмы *split–apply–combine*: разделить данные на группы, применить к каждой группе функцию и затем объединить результаты.

- Группировка (*grouping*) — разбиение набора данных на подгруппы по значению одного или нескольких ключевых столбцов (например, по группе, региону, категории товара).
- Агрегирование (*aggregation*) — применение к каждой группе сводных функций (сумма, среднее, количество, минимум/максимум, пользовательские функции).

Метафора: *группировка* — это «разложить документы по папкам», а *агрегирование* — «подсчитать итоги в каждой папке».

1.2.4 Визуализация данных

Визуализация данных — это представление числовой информации в виде графиков, диаграмм и других визуальных форм, чтобы выявлять тенденции, сравнения и закономерности, которые сложно увидеть в сырой таблице. Простыми словами: *график* — это «язык, на котором данные разговаривают с людьми».

2. Основная часть

2.1 Теоретический фундамент: «split–apply–combine» и расширенный анализ

2.1.1 Парадигма *split–apply–combine*

Документация *pandas* описывает метод *groupby* как трёхшаговый процесс:

1. *Split* (разделить) — разбить данные на группы по одному или нескольким ключам (например, по *group*, *subject*).
2. *Apply* (применить) — применить к каждой группе функцию (*sum*, *mean*, *count*, *min*, *max*, пользовательскую).

3. Combine (объединить) — собрать результаты в новую таблицу (DataFrame/Series).

Метафора: *представьте стопку ведомостей; сначала вы раскладываете их по группам (split), затем в каждой папке считаете сводные показатели (apply), а потом собираете итоги в одну сводную ведомость (combine).*

2.1.2 Роль NumPy в pandas-аналитике

pandas построен поверх NumPy-массивов:

- каждая числовая колонка DataFrame внутри хранится как NumPy-массив;
- агрегирующие функции pandas (mean, sum, std) используют векторизованные операции NumPy для эффективности;
- многие математические и статистические операции можно выполнять как через NumPy, так и через pandas.

Теоретически это означает, что NumPy обеспечивает числовой фундамент (операции над массивами), а pandas — более высокоуровневую табличную абстракцию и удобный интерфейс.

2.2 Группировка и агрегирование в pandas

2.2.1 Базовая группировка: один ключ

Пример из руководств: `df.groupby('group')['grade'].mean()` — сгруппировать строки по значению столбца `group` и вычислить средний балл по каждой группе.

Теоретически:

- множество всех записей разбивается на подмножества с одинаковым значением `group`;
- к каждому подмножеству применяется функция `mean`;
- результат — отображение `group` → `средний балл`.

Простыми словами: мы «спрашиваем у данных»: *какую среднюю оценку имеет каждая группа?*

2.2.2 Многомерная группировка: несколько ключей

GroupBy поддерживает группировку по нескольким столбцам, например `['group', 'subject']`:

- это позволяет строить «куб» данных (группа × предмет) и видеть, как показатели меняются по двум измерениям;
- результат может иметь иерархический индекс (MultiIndex), что важно понимать на уровне теории структур данных.

Метафора: *мы раскладываем ведомости по «двум осям» — сначала по группе, внутри — по предмету.*

2.2.3 Агрегирующие функции и **agg**

pandas позволяет применять сразу несколько агрегирующих функций к одной группе с помощью **agg**:

- стандартные функции: **sum**, **mean**, **count**, **min**, **max**, **std**, **median**;
- собственные функции через **lambda** (например, «средний балл + 5», «размах»).

Пример из документации: **df.groupby('A').B.agg(['min', 'max'])** — минимальное и максимальное значение B по каждой категории A.

Теоретически это соответствует построению нескольких сводных показателей по каждой группе — то, что в бизнесе часто реализуют через сводные таблицы.

2.3 Расширенный анализ в NumPy

2.3.1 Массивы и оси

NumPy-массивы поддерживают операции по осям:

- сумма по строкам или столбцам;
- средние значения;
- операции линейной алгебры (матрицы, произведения).

Простыми словами: *NumPy позволяет выполнять массовые операции над рядами и матрицами чисел за один шаг, что важно при работе с большими наборами.*

2.3.2 Применение к анализу

Курсы по NumPy и pandas для анализа данных показывают, что NumPy удобен для:

- низкоуровневых числовых преобразований (масштабирование, нормализация, стандартизация);
- генерации тестовых данных (рандомные массивы);
- реализации математических моделей (линейные комбинации, регрессии — на базовом уровне).

На уровне модуля «Применение ИКТ» NumPy можно использовать для:

- расчёта статистик по массивам оценок;
 - работы с временными рядами (последовательности измерений);
 - подготовительных шагов перед анализом в pandas.
-

2.4 Визуализация сгруппированных и агрегированных данных

2.4.1 pandas + Matplotlib/Seaborn

pandas GroupBy-объекты поддерживают методы визуализации, такие как `.plot()` и `.hist()`, что позволяет сразу строить графики по результатам группировки:

- `grouped['grade'].mean().plot(kind='bar')` — средний балл по группам в виде столбчатого графика;
- `df.groupby('category')['sales'].sum().plot(kind='bar')` — суммарные продажи по категориям.

Seaborn, в свою очередь, предоставляет более «статистически ориентированные» визуализации (boxplot, violinplot, barplot с доверительными интервалами), что полезно для расширенного анализа.

2.4.2 Связь визуализации и интерпретации

Теоретически важно понимать:

- выбор типа графика зависит от типа данных (временные ряды → line, категориальные → bar);
- визуализация показывает агрегированные показатели, а не сырые данные;
- интерпретация графика — это шаг, где аналитик формулирует выводы и гипотезы, а не только «рисует картинку».

Метафора: *группировка и агрегирование — это «подведение итогов», а визуализация — «презентация этих итогов в понятном виде».*

3. Практические примеры и мини-кейсы

3.1 Кейс 1 (колледж): расширенный анализ успеваемости

Ситуация:

Администрация колледжа хочет понять, как успеваемость по модулю «Применение ИКТ» зависит от группы и формы обучения (очная/дистанционная).

Данные:

Таблица `grades_ikt` со столбцами: `student_id`, `group`, `mode` (формат), `topic`, `grade`, `date`.

Задача анализа:

1. Группировка и агрегирование:
 - средний балл по сочетаниям (`group`, `mode`);
 - доля оценок ниже порога (например, 50).
2. Визуализация:
 - столбчатая диаграмма средних баллов по группам (две серии — очно/дистанционно);
 - boxplot распределения оценок по формату обучения.

3. Выводы:

- есть ли существенные различия между формами;
- какие группы требуют особого внимания.

Такой кейс иллюстрирует описательный и сравнительный анализ, использующий `groupby`, `agg` и графики.

3.2 Кейс 2 (бизнес): анализ продаж по категориям и регионам

Ситуация:

Торговая сеть хочет видеть сводные отчёты по продажам: какие категории товаров приносят наибольшую выручку в разных регионах.

Данные:

`date`, `product`, `category`, `region`, `quantity`, `price`, `revenue`.

Аналитический workflow:

1. Группировка: `df.groupby(['region', 'category'])['revenue'].sum()` — суммарная выручка по категориям в каждом регионе.
 2. Агрегирование: дополнительный расчёт среднего чека и количества транзакций.
 3. Визуализация:
 - `heatmap` (`region` × `category`) по выручке;
 - `barplot` топ-категорий в целом.
 4. Интерпретация:
 - какие комбинации регион–категория наиболее прибыльны;
 - где потенциал для расширения или оптимизации ассортимента.
-

3.3 Кейс 3 (госорганы): анализ обращений граждан по видам услуг

Ситуация:

Госорган анализирует обращения граждан по видам услуг (образование, соцподдержка, медицина) и регионам, чтобы улучшить качество сервисов в рамках «Цифрового Казахстана».

Данные:

`request_id`, `region`, `service_type`, `channel`, `processing_time_days`, `status`.

Расширенный анализ:

1. Группировка: `df.groupby(['region', 'service_type'])['processing_time_days'].agg(['mean', 'count'])`.
2. Выделение групп с превышением порогового среднего времени обработки.
3. Визуализация:

- barplot среднего времени обработки по видам услуг;
- график количества обращений по регионам.

4. Выводы:

- где перегружены сервисы;
- какие услуги требуют оптимизации процессов.

Такой кейс напрямую связывает pandas-аналитику с задачами цифрового госуправления.

4. Практические задания

4.1 Задание 1: Теоретическое понимание groupby (без кода)

Цель: осознать идею split–apply–combine.

1. Дан фрагмент таблицы успеваемости (10–15 строк) с колонками **group**, **subject**, **grade**.
 2. На бумаге:
 - сгруппируйте строки по **group** (разложите по «папкам»);
 - для каждой группы вручную посчитайте средний балл;
 - оформите сводную мини-таблицу (group → mean grade).
 3. Ответьте:
 - что означает split, apply, combine в вашем ручном примере;
 - какие возможные ошибки вы могли бы допустить без автоматизации.
-

4.2 Задание 2: Группировка и агрегирование в pandas

Цель: применить groupby и agg к учебным данным.

1. Загрузите учебный CSV с успеваемостью или результатами теста.
 2. Выполните:
 - группировку по **group** и **subject**;
 - агрегирование: средний балл, количество записей, долю оценок ниже порога (через пользовательскую функцию).
 3. Сохраните результат в новый DataFrame.
 4. Напишите 5–7 предложений с выводами (какие группы/предметы выделяются).
-

4.3 Задание 3: Визуализация сгруппированных данных

Цель: научиться связывать агрегированные данные с графиками.

1. Используя результат из задания 4.2, постройте:
 - столбчатую диаграмму средних баллов по группам;

- при желании — heatmap по группам и предметам (если по программе допустима работа с Seaborn).

2. Формально опишите:

- что показывает каждый график;
 - какие выводы можно сделать;
 - какие ограничения у такой визуализации (нет детализации по студентам и т.п.).
-

4.4 Задание 4 (проект): мини-дашборд для колледжа

Цель: связать группировку, агрегирование и визуализацию в одной задаче.

В группах по 3–4 человека:

1. Выберите одну тему (успеваемость, посещаемость, участие в мероприятиях).
 2. Сформируйте или получите учебный набор данных.
 3. В pandas:
 - выполните 2–3 группировки (по группе, по типу мероприятия, по месяцу);
 - рассчитайте ключевые показатели (mean, count, возможно, процент).
 4. Визуализируйте 3–4 графика (бар-графики, линейные графики, гистограммы).
 5. Подготовьте краткий отчёт (1–2 страницы), где:
 - опишете данные и методы;
 - сформулируете выводы;
 - свяжете проект с задачами «Білім. 2025» и «Цифрового Казахстана» (как такая аналитика может помочь управлению колледжа).
-

5. Выводы и рекомендации

5.1 Ключевые выводы

1. Группировка и агрегирование в pandas реализуют мощную парадигму *split–apply–combine*, позволяющую системно анализировать большие наборы данных по группам и измерениям.
2. NumPy обеспечивает числовой фундамент для pandas, а связка «NumPy + pandas + визуализация» позволяет выполнять расширенный анализ данных, необходимый для задач образования, бизнеса и госуправления.
3. Освоение этих приёмов на уровне модуля «Применение ИКТ» отвечает национальной AI-рамке Казахстана и приоритетам развития ИКТ-навыков, продвигая студентов от базового владения таблицами к осознанной аналитике и проектной деятельности.

5.2 Рекомендации студентам

- В каждой задаче чётко формулировать вопрос к данным (какие группы и показатели важны), а затем переводить его в операции `groupby`, `agg` и визуализацию.
 - Стараться не только «получить код, который работает», но и проговаривать теоретически, какой вид анализа выполняется (описательный, сравнительный), какие структуры данных и абстракции используются.
 - Использовать учебные курсы по NumPy и pandas для закрепления материала и работы с более сложными кейсами.
-

6. Список литературы и интернет-ресурсов

1. Kazakhstan adopts national standards for the use of AI in education (2025–2029). О национальной AI-рамке, этике, защите данных и модели *Acquire* → *Deepen* → *Create*. URL:
2. <https://digitalrights.asia/events/kazakhstan-ai-education-standards-2025-2029/>
- 3.
4. Kazakhstan Establishes National Standards for Artificial Intelligence in Education. Об интеграции ИИ-тем (включая данные и аналитику) в школы и колледжи. URL:
5. <https://astanatimes.com/2025/09/kazakhstan-establishes-national-standards-for-artificial-intelligence-in-education/>
- 6.
7. Kazakhstan sets unified AI standards for secondary and vocational education. Краткое изложение целей AI-рамки и трёхуровневой модели ИИ-грамотности. URL:
8. <https://www.trend.az/business/4092187.html>
- 9.
10. ICT Skills Development in the Republic of Kazakhstan: Insight Report with Recommendations. Аналитика UNESCO по развитию ИКТ- и дата-навыков, связи с цифровой экономикой и образованием. URL:
11. <https://iite.unesco.org/publications/ict-skills-development-in-the-republic-of-kazakhstan-insight-report-with-recommendations/>
- 12.
13. pandas GroupBy: Your Guide to Grouping Data in Python. Подробное руководство по `groupby`, `split-apply-combine` и расширенным приёмам группировки. URL:
14. <https://realpython.com/pandas-groupby/>
- 15.
16. Group by: split-apply-combine — pandas documentation. Официальное описание концепции группировки и возможностей агрегирования и визуализации. URL:
17. https://pandas.pydata.org/docs/user_guide/groupby.html
- 18.
19. Grouping and Aggregating with Pandas. Статья с наглядными примерами `groupby` и `agg`. URL:
20. <https://www.geeksforgeeks.org/python/grouping-and-aggregating-with-pandas/>

21.

22. Data Analysis with NumPy and Pandas Specialization. Специализация, где акцентируются навыки группировки, агрегирования и визуализации данных. URL:

23. <https://www.coursera.org/specializations/data-analysis-numpy-pandas>

24.

25. NumPy for Absolute Beginners: A Project-Based Approach to Data Analysis.

Объяснение базовых и продвинутых приёмов NumPy через проектный подход.

URL:

26. <https://towardsdatascience.com/numpy-for-absolute-beginners-a-project-based-approach-to-data-analysis/>